

Como um Robô Aprende a Conversar?

Um guia para quem tem 10 anos (ou mais!) entender o que acontece dentro de uma Inteligência Artificial

Baseado nas ideias e visualizações do site **LLM Lens**, um projeto que mostra, passo a passo, como um modelo de linguagem pensa.

Feito para acompanhar o site llm-lens • Trabalho de Conclusão de Curso

O que vamos descobrir neste livrinho

- 1 O que é essa coisa que conversa com a gente?
- 2 Como um computador lê palavras (pedacinhos e números)
- 3 Os 12 andares da fábrica de pensar
- 4 Os detetives de atenção
- 5 O mapa dos significados
- 6 Como o robô escolhe a próxima palavra
- 7 Segredos por trás do site LLM Lens
- 8 Glossário: palavras difíceis explicadas fácil

Antes de começar: sempre que você ver uma palavra em **laranja**, ela está explicada de novo, com outras palavras, no glossário no final do livro.

CAPÍTULO 1

O que é essa coisa que conversa com a gente?

Você já conversou com um assistente de computador, tipo o ChatGPT, e ele respondeu como se entendesse o que você disse? Pois é... na verdade, ele não *entende* como a gente entende. Ele é uma máquina de **adivinhar a próxima palavra**, só que ele é muito, muito bom nisso, porque leu bilhões de frases antes.

Esse tipo de programa se chama **LLM** — sigla, em inglês, para “Modelo Grande de Linguagem”. “Grande” porque tem um monte de peças por dentro (vamos ver quantas!), e “de Linguagem” porque a coisa que ele aprendeu a fazer é lidar com palavras.

Pensa assim: é parecido com aquele joguinho de adivinhar a próxima palavra do celular, quando você digita “Vou pedir uma pizza de...” e ele sugere “queijo” — só que MUITO mais esperto, porque consegue lembrar de frases inteiras, não só da última palavra.

O site **LLM Lens**, que este livro acompanha, deixa você abrir essa “caixa preta” e ver, em tempo real, os passos que um modelo chamado **GPT-2** segue para escrever uma resposta — tudo rodando dentro do seu próprio navegador, sem precisar de internet depois de carregado!

CAPÍTULO 2

Como um computador lê palavras

Computadores só entendem números. Então, antes de pensar em qualquer frase, o modelo precisa transformar as palavras em números. Isso acontece em dois passos.

Passo 1 — Cortar em pedacinhos (tokens)


Em vez de usar a palavra inteira, o modelo corta o texto em pedacinhos menores, chamados **tokens**. Uma palavra grande e rara, tipo “impressionadíssima”, pode virar três pedacinhos: *impress*, *ion* e *adíssima*. Palavras curtas e comuns, tipo “gato”, geralmente viram um token só.



Passo 2 — Virar um pontinho num mapa (embeddings)

Cada token vira um número (tipo um código de identificação), e depois esse número é transformado em um monte de números juntos — imagina um endereço bem detalhado, tipo as coordenadas de um GPS, mas com centenas de “eixos” em vez de só dois (latitude/longitude). Isso se chama **embedding**.

A mágica é que palavras parecidas ficam pertinho umas das outras nesse mapa. “Gato” fica perto de “cachorro” e de “gatinho”, mas longe de “carro” ou “ônibus”.




No mapa de significados, palavras parecidas ficam vizinhas.

CAPÍTULO 3

Os 12 andares da fábrica de pensar

Depois que a frase virou números, ela passa por uma espécie de fábrica com vários andares empilhados. Cada andar se chama **camada** (em inglês, *layer*). O modelo que o site usa, o GPT-2 pequeno, tem **12 camadas**.

A frase entra pelo andar 1, é processada e melhorada um pouquinho, sobe pro andar 2, é melhorada de novo, sobe pro 3... até chegar no andar 12. Em cada andar, o modelo entende um pouco melhor o que a frase quer dizer — os primeiros andares costumam perceber coisas mais simples (tipo gramática), e os últimos andares já entendem coisas mais complicadas (tipo o sentido geral da frase).



A frase sobe andar por andar, ficando mais “entendida” em cada um.

É tipo montar um sanduíche: em cada camada você adiciona um ingrediente, e o sanduíche final (depois do andar 12) é bem mais completo do que o pão sozinho que entrou lá embaixo.


CAPÍTULO 4

Os detetives de atenção

Dentro de cada andar da fábrica, tem uma equipe de “detetives” trabalhando ao mesmo tempo. Cada detetive se chama **cabeça de atenção** (em inglês, *attention head*). O GPT-2 pequeno tem **12 detetives por andar** — e como são 12 andares, isso dá 144 detetives no total!

O trabalho de cada detetive é olhar pra uma palavra e decidir: “pra entender essa palavra direito, em quais OUTRAS palavras da frase eu preciso prestar atenção?”

Por exemplo, na frase “O gato subiu no telhado”, para entender bem a palavra “gato”, um detetive pode prestar atenção em “O” (pra saber que é uma coisa só, não várias), outro detetive presta atenção em “subiu” (pra saber o que o gato fez), e outro em “telhado” (pra saber pra onde ele foi). Cada detetive tem uma especialidade diferente!



No site, você pode escolher qual andar e qual detetive quer espiar, e ver exatamente pra onde as setas de atenção apontam! Às vezes um detetive até “olha pra si mesmo” — isso também é normal e importante.

CAPÍTULO 5

O mapa dos significados

Lembra que cada palavra virou um pontinho num mapa com centenas de “eixos”? Isso é informação demais pra um ser humano enxergar de uma vez — a gente só consegue olhar bem para mapas com 2 eixos (tipo largura e altura de uma folha de papel).

Por isso, o site usa um truque matemático chamado **PCA** (um jeito de “achatar” o mapa gigante em só 2 dimensões, tentando não perder as distâncias mais importantes entre as palavras) para desenhar esse mapa numa tela, como se fosse um raio-x do que o modelo está “pensando” sobre cada palavra, andar por andar.

É como tirar uma foto de uma escultura 3D de vários ângulos diferentes, achando o melhor ângulo pra você entender a forma dela numa imagem só, plana.

CAPÍTULO 6

Como o robô escolhe a próxima palavra

Depois de passar pelos 12 andares e por todos os detetives, o modelo já entendeu muito bem a frase. Agora ele precisa decidir: qual é a palavra mais provável de vir a seguir?

Ele não escolhe só UMA palavra de cara. Primeiro, ele calcula uma **porcentagem de chance** para MUITAS palavras diferentes — e normalmente escolhe (ou sorteia, com mais chance pras palavras mais prováveis) entre as que tiveram maior porcentagem.



O modelo calcula a chance de cada palavra possível continuar a frase.

Depois de escolher uma palavra, ele recomeça o processo inteiro — de novo pelos 12 andares — considerando agora a frase JÁ com essa nova palavra, pra escolher a palavra seguinte. É por isso que gerar um texto longo demora mais: o modelo repete essa “subida na fábrica” uma vez para cada palavra nova!

CAPÍTULO 7

Segredos por trás do site LLM Lens

Algumas curiosidades sobre como o site foi construído, para quem gosta de saber o que tem “por trás das cortinas”:

Roda no seu navegador, não em um servidor distante

O modelo inteiro (os “144 detetives” e tudo mais) é baixado uma vez e roda direto no seu computador ou celular, usando uma tecnologia chamada [ONNX Runtime Web](#). Isso significa mais privacidade: o que você digita não precisa viajar pra nenhum outro computador.

O modelo foi “comprimido”

Para caber e rodar rápido no navegador, o modelo passou por um processo chamado [quantização](#): em vez de guardar os números com altíssima precisão, ele guarda versões mais “arredondadas”, ocupando bem menos espaço, quase sem perder qualidade nas respostas.

Existem dois modelos: um de português e um de inglês

Cada idioma tem seu próprio “cérebro” treinado, porque as regras e os padrões de cada língua são diferentes.

CAPÍTULO 8

Glossário: palavras difíceis explicadas fácil

LLM

Sigla em inglês para “Modelo Grande de Linguagem” — um programa treinado com muitíssimo texto para prever a próxima palavra de uma frase.

Token

Um pedacinho de palavra (ou uma palavra inteira, se ela for curtinha). É a “unidade” que o modelo realmente lê.

Embedding

A “tradução” de um token em uma lista de números, criando um endereço num mapa de significados.

Camada (layer)

Um “andar” da fábrica de pensar do modelo. O GPT-2 pequeno tem 12 camadas empilhadas.

Cabeça de atenção (attention head)

Um “detetive” dentro de uma camada, especializado em perceber um tipo de relação entre as palavras da frase.

PCA

Uma ferramenta matemática que “achata” um mapa com muitas dimensões em um mapa de só 2 dimensões, fácil de desenhar numa tela.

Quantização

Processo de deixar os números do modelo mais “simples” (menos casas decimais), para ele ocupar menos espaço e rodar mais rápido.

ONNX Runtime Web

A tecnologia que permite rodar um modelo de Inteligência Artificial direto dentro do navegador, sem precisar de um servidor.

Agora que você já sabe o que são tokens, camadas, cabeças de atenção e mapas de significado, que tal abrir o site **LLM Lens** e ver tudo isso acontecendo ao vivo, com as suas próprias frases?